



کسری شیخی
۴۰۳۱۱۰۵۹۶

هوش مصنوعی
نیم سال دوم ۰۴-۰۵
استاد: ماری اوریاد

دانشکده مهندسی کامپیوتر

تمرین چهارم

سؤال اول

(آ) نادرست.

در الگوریتم Naive Bayes فرض نمی شود که ویژگی ها به طور کلی نسبت به یکدیگر مستقل باشند. فرض اصلی این است که ویژگی ها به شرط دانستن کلاس مستقل هستند. یعنی اگر کلاس را با Y و ویژگی ها را با $X_1, \dots, X_n$ نشان دهیم، داریم:

$$P(X_1, \dots, X_n | Y) = \prod_{i=1}^n P(X_i | Y)$$

پس استقلال ویژگی ها از نوع استقلال شرطی نسبت به کلاس است، نه استقلال مطلق.

(ب) درست.

در Naive Bayes احتمال پسین شامل ضرب احتمال های شرطی ویژگی هاست:

$$P(Y = y | X_1, \dots, X_n) \propto P(Y = y) \prod_{i=1}^n P(X_i | Y = y)$$

اگر یکی از این احتمال ها صفر شود، کل حاصل ضرب و در نتیجه احتمال پسین آن کلاس صفر می شود. Smoothing از این صفر شدن جلوگیری می کند و همچنین وابستگی بیش از حد مدل به داده های آموزشی را کاهش می دهد؛ پس می تواند از Overfitting نیز جلوگیری کند.

(ج) نادرست.

درخت تصمیم فقط برای مسائل Classification استفاده نمی شود. درخت تصمیم می تواند برای مسائل رگرسیون نیز استفاده شود.

(د) درست.

هرچه عمق درخت تصمیم بیشتر شود، مدل پیچیده‌تر می‌شود و می‌تواند جزئیات بیشتری از داده‌های آموزشی را یاد بگیرد. اگر درخت بیش از حد عمیق شود، ممکن است به جای یاد گرفتن الگوی کلی داده‌ها، نویزها و جزئیات تصادفی داده‌های آموزشی را حفظ کند. در این حالت مدل روی داده‌های آموزش عملکرد خوبی دارد، اما روی داده‌های جدید عملکرد ضعیف‌تری خواهد داشت. بنابراین با افزایش عمق درخت، احتمال Overfitting بیشتر می‌شود.

(ه) درست.

معیار Information Gain به صورت زیر است:

$$IG(Y, X) = H(Y) - H(Y | X)$$

ویژگی‌هایی که مقدارهای یکتای زیادی دارند، داده‌ها را به شاخه‌های کوچک‌تر و خالص‌تر تقسیم می‌کنند؛ بنابراین مقدار $H(Y | X)$ کاهش می‌یابد و Information Gain زیاد می‌شود. پس این معیار تمایل دارد چنین ویژگی‌هایی را انتخاب کند.

(و) نادرست.

درخت تصمیم می‌تواند روابط غیرخطی را مدل کند؛ چون ترکیب شرط‌های ساده در گره‌های مختلف می‌تواند مرز تصمیم پیچیده و غیرخطی بسازد. بنابراین گزاره نادرست است.

(ز) درست.

اگر مدل هم روی داده‌های Train و هم روی داده‌های Validation عملکرد ضعیفی داشته باشد، یعنی حتی الگوی کلی داده‌های آموزشی را هم خوب یاد نگرفته است. این حالت نشانه‌ی Underfitting است.

(ح) نادرست.

داده‌های آموزش برای یادگیری پارامترهای مدل استفاده می‌شوند. اما برای انتخاب ابرپارامترها معمولاً از داده‌های Validation یا روش Cross Validation استفاده می‌شود. بنابراین گزاره نادرست است.

سؤال دوم

(آ) تعداد کل داده‌ها برابر است با:

10

از بین این داده‌ها، تعداد داده‌های کلاس 1 برابر با 3 و تعداد داده‌های کلاس 0 برابر با 7 است. بنابراین آنتروپی اولیه به صورت زیر محاسبه می‌شود:

$$H(Y) = -\frac{3}{10} \log_2 \frac{3}{10} - \frac{7}{10} \log_2 \frac{7}{10}$$

$$H(Y) \simeq 0.881$$

برای انتخاب بهترین ویژگی در گره ریشه، مقدار Information Gain را برای هر ویژگی محاسبه می‌کنیم:

$$IG(Y, X) = H(Y) - H(Y|X)$$

بررسی ویژگی X_1 :

برای حالت $X_1 = 0$ ، تعداد 4 داده داریم. از بین این داده‌ها، 1 داده متعلق به کلاس 1 و 3 داده متعلق به کلاس 0 هستند. پس داریم:

$$H(Y|X_1 = 0) = -\frac{1}{4} \log_2 \frac{1}{4} - \frac{3}{4} \log_2 \frac{3}{4} \simeq 0.811$$

برای حالت $X_1 = 1$ ، تعداد 6 داده داریم. از بین این داده‌ها، 2 داده متعلق به کلاس 1 و 4 داده متعلق به کلاس 0 هستند. پس داریم:

$$H(Y|X_1 = 1) = -\frac{2}{6} \log_2 \frac{2}{6} - \frac{4}{6} \log_2 \frac{4}{6} \simeq 0.918$$

بنابراین آنتروپی شرطی نسبت به ویژگی X_1 برابر است با:

$$H(Y|X_1) = \frac{4}{10}(0.811) + \frac{6}{10}(0.918) \simeq 0.875$$

پس مقدار Information Gain برای ویژگی X_1 برابر است با:

$$IG(Y, X_1) = 0.881 - 0.875 = 0.006$$

بررسی ویژگی X_2 :

برای حالت $X_2 = 0$ ، تعداد 3 داده داریم و هر سه داده متعلق به کلاس 0 هستند. بنابراین این گره خالص است و داریم:

$$H(Y|X_2 = 0) = 0$$

برای حالت $X_2 = 1$ ، تعداد 7 داده داریم. از بین این داده‌ها، 3 داده متعلق به کلاس 1 و 4 داده متعلق به کلاس 0 هستند. پس داریم:

$$H(Y|X_2 = 1) = -\frac{3}{7} \log_2 \frac{3}{7} - \frac{4}{7} \log_2 \frac{4}{7} \simeq 0.985$$

بنابراین آنتروپی شرطی نسبت به ویژگی X_2 برابر است با:

$$H(Y|X_2) = \frac{3}{10}(0) + \frac{7}{10}(0.985) \simeq 0.690$$

پس مقدار Information Gain برای ویژگی X_2 برابر است با:

$$IG(Y, X_2) = 0.881 - 0.690 = 0.191$$

بررسی ویژگی X_3 :

برای حالت $X_3 = 0$ ، تعداد 4 داده داریم. از بین این داده‌ها، 1 داده متعلق به کلاس 1 و 3 داده متعلق به کلاس 0 هستند. پس داریم:

$$H(Y|X_3 = 0) = -\frac{1}{4} \log_2 \frac{1}{4} - \frac{3}{4} \log_2 \frac{3}{4} \simeq 0.811$$

برای حالت $X_3 = 1$ ، تعداد 6 داده داریم. از بین این داده‌ها، 2 داده متعلق به کلاس 1 و 4 داده متعلق به کلاس 0 هستند. پس داریم:

$$H(Y|X_3 = 1) = -\frac{2}{6} \log_2 \frac{2}{6} - \frac{4}{6} \log_2 \frac{4}{6} \simeq 0.918$$

بنابراین آنتروپی شرطی نسبت به ویژگی X_3 برابر است با:

$$H(Y|X_3) = \frac{4}{10}(0.811) + \frac{6}{10}(0.918) \simeq 0.875$$

پس مقدار Information Gain برای ویژگی X_3 برابر است با:

$$IG(Y, X_3) = 0.881 - 0.875 = 0.006$$

در نتیجه مقادیر به دست آمده به صورت زیر هستند:

$$IG(Y, X_1) = 0.006$$

$$IG(Y, X_2) = 0.191$$

$$IG(Y, X_3) = 0.006$$

چون ویژگی X_2 بیشترین مقدار Information Gain را دارد، بهترین ویژگی برای انشعاب در گره ریشه برابر است با:

$$X_2$$

(ب) خیر. اگر درخت را آنقدر رشد دهیم که همه برگ‌ها خالص شوند، مدل روی داده‌های آموزشی دقت 100% می‌گیرد؛ اما این لزوماً به معنی عملکرد بهتر روی داده‌های تست نیست.

دلیلش این است که مدل ممکن است جزئیات و نویزهای داده‌های آموزشی را حفظ کند و الگوی کلی مسئله را خوب یاد نگیرد. (همان Overfitting)

سؤال سوم

(آ) ایمیل داده‌شده به صورت مقابل است:

best price

در نظر می‌گیریم $P(Y = \text{spam}) = p$ ، در نتیجه داریم $P(Y = \text{ham}) = 1 - p$.
برای اینکه این ایمیل به عنوان spam طبقه‌بندی شود، باید امتیاز کلاس spam از امتیاز کلاس ham بیشتر باشد.

$$S_{\text{spam}} = P(Y = \text{spam})P(W = \text{best} | Y = \text{spam})P(W = \text{price} | Y = \text{spam})$$

$$S_{\text{ham}} = P(Y = \text{ham})P(W = \text{best} | Y = \text{ham})P(W = \text{price} | Y = \text{ham})$$

پس شرط لازم برای spam شدن ایمیل این است که:

$$S_{\text{spam}} > S_{\text{ham}}$$

حالا با جایگذاری مقادیر جدول داریم:

$$p \cdot \frac{1}{8} \cdot \frac{1}{4} > (1 - p) \cdot \frac{1}{12} \cdot \frac{1}{6}$$

$$\frac{p}{32} > \frac{1 - p}{72}$$

$$72p > 32(1 - p)$$

$$72p > 32 - 32p$$

$$104p > 32$$

$$p > \frac{32}{104}$$

$$p > \frac{4}{13}$$

پس اگر داشته باشیم:

$$P(Y = \text{spam}) > \frac{4}{13}$$

این ایمیل به عنوان spam طبقه‌بندی می‌شود.

(ب) در این بخش پنج ایمیل آموزشی داریم که دو ایمیل از نوع spam و سه ایمیل از نوع ham هستند. ایمیل‌های spam برابرند با:

special offer just today

summer season off just for you

تعداد کل کلمات در ایمیل‌های spam برابر است با:

$$4 + 6 = 10$$

کلمه‌ی just در ایمیل‌های spam دو بار آمده است. پس داریم:

$$P(W = \text{just} \mid Y = \text{spam}) = \frac{2}{10} = \frac{1}{5}$$

ایمیل‌های ham برابرند با:

meeting today

call me later

see you tomorrow

تعداد کل کلمات در ایمیل‌های ham برابر است با:

$$2 + 3 + 3 = 8$$

کلمه‌ی call در ایمیل‌های ham یک بار آمده است. پس داریم:

$$P(W = \text{call} \mid Y = \text{ham}) = \frac{1}{8}$$

کلمه‌ی offer در هیچ‌کدام از ایمیل‌های ham نیامده است. چون در این بخش از smoothing استفاده نمی‌کنیم، احتمال آن صفر می‌شود:

$$P(W = \text{offer} \mid Y = \text{ham}) = \frac{0}{8} = 0$$

از بین پنج ایمیل آموزشی، دو ایمیل spam هستند. بنابراین:

$$P(Y = \text{spam}) = \frac{2}{5}$$

پس جواب‌های نهایی برابرند با:

$$P(W = \text{just} \mid Y = \text{spam}) = \frac{1}{5}$$

$$P(W = \text{call} \mid Y = \text{ham}) = \frac{1}{8}$$

$$P(W = \text{offer} \mid Y = \text{ham}) = 0$$

$$P(Y = \text{spam}) = \frac{2}{5}$$

سؤال چهارم

آ می‌خواهیم شبکه‌ای با حداکثر ۳ لایه‌ی مخفی بسازیم که خروجی آن برابر باشد با:

$$f(x_1, x_2, x_3) = \min(x_1, x_2^{x_3})$$

ابتدا داریم:

$$x_2^{x_3} = e^{x_3 \ln(x_2)}$$

و از آن‌جا که:

$$x_3 \ln(x_2) = e^{\ln(x_3) + \ln(\ln(x_2))}$$

پس می‌توان نوشت:

$$x_2^{x_3} = e^{e^{\ln(x_3) + \ln(\ln(x_2))}}$$

بنابراین کافی است شبکه ابتدا مقادیر $\ln(x_3)$ و $\ln(\ln(x_2))$ را بسازد، سپس از آن‌ها مقدار $x_2^{x_3}$ را تولید کند. همچنین برای ساختن تابع min از رابطه‌ی زیر استفاده می‌کنیم:

$$\min(a, b) = \frac{a + b - |a - b|}{2}$$

در نتیجه:

$$\min(x_1, x_2^{x_3}) = \frac{x_1 + x_2^{x_3} - |x_1 - x_2^{x_3}|}{2}$$

لایه‌ی مخفی اول:

در این لایه سه مقدار زیر ساخته می‌شوند:

$$h_1^{(1)} = \ln(x_3)$$

$$h_2^{(1)} = \ln(\ln(x_2))$$

$$h_3^{(1)} = x_1$$

تابع فعال‌سازی نورون اول $\phi(t) = \ln(t)$ ، نورون دوم $\phi(t) = \ln(\ln(t))$ و نورون سوم تابع همانی است.

لایه‌ی مخفی دوم:

نورون اول این لایه جمع دو خروجی اول لایه‌ی قبل را دریافت می‌کند و تابع فعال‌سازی آن را به صورت

$$\phi(t) = e^t$$

در نظر می‌گیریم. بنابراین:

$$h_1^{(2)} = e^{h_1^{(1)} + h_2^{(1)}} = e^{e^{\ln(x_3)} + \ln(\ln(x_2))} = x_2^{x_3}$$

نورون دوم مقدار x_1 را عبور می‌دهد:

$$h_2^{(2)} = x_1$$

لایه‌ی مخفی سوم:

در این لایه دو مقدار لازم برای رابطه‌ی $\min$ ساخته می‌شود:

$$h_1^{(3)} = h_1^{(2)} + h_2^{(2)} = x_2^{x_3} + x_1$$

$$h_2^{(3)} = |h_2^{(2)} - h_1^{(2)}| = |x_1 - x_2^{x_3}|$$

تابع فعال‌سازی نورون اول همانی و تابع فعال‌سازی نورون دوم $\phi(t) = |t|$ است.

لایه‌ی خروجی:


تابع فعال‌سازی لایه‌ی خروجی همانی است و خروجی به صورت ترکیب خطی زیر ساخته می‌شود:

$$y = \frac{1}{2}h_1^{(3)} - \frac{1}{2}h_2^{(3)}$$

پس:

$$y = \frac{x_1 + x_2^{x_3} - |x_1 - x_2^{x_3}|}{2} = \min(x_1, x_2^{x_3})$$

بنابراین شبکه‌ی طراحی شده تابع خواسته شده را محاسبه می‌کند.



(ب) تابع داده شده برابر است با:

$$f(w, x) = \frac{1}{1 + e^{-(w_0x_0 + w_1x_1 + w_2x_2)}}$$

و مقادیر ورودی‌ها عبارت‌اند از:

$$w_0 = 2, \quad x_0 = -1, \quad w_1 = -3, \quad x_1 = -2, \quad w_2 = -3$$

pass: Forward

مقادیر رأس‌های گراف را به ترتیب حساب می‌کنیم:

$$a = w_0x_0 = 2(-1) = -2$$

$$b = w_1x_1 = (-3)(-2) = 6$$

$$c = a + b = -2 + 6 = 4$$

$$d = c + w_2 = 4 - 3 = 1$$

$$e = -d = -1$$

$$r = e^e = e^{-1} \simeq 0.367$$

$$s = r + 1 \simeq 1.367$$

$$f = \frac{1}{s} \simeq 0.731$$

pass: Backward

از خروجی نهایی شروع می‌کنیم:

$$\frac{\partial f}{\partial f} = 1$$

چون $f = \frac{1}{s}$ ، داریم:

$$\frac{\partial f}{\partial s} = -\frac{1}{s^2} \simeq -\frac{1}{(1.367)^2} \simeq -0.535$$

از آنجا که $s = r + 1$ ، پس:

$$\frac{\partial f}{\partial r} = \frac{\partial f}{\partial s} \simeq -0.535$$

و چون $r = e^e$ ، داریم:

$$\frac{\partial f}{\partial e} = \frac{\partial f}{\partial r} e^e \simeq (-0.535)(0.367) \simeq -0.196$$

چون $e = -d$ ، نتیجه می‌شود:

$$\frac{\partial f}{\partial d} \simeq 0.196$$

همچنین چون $d = c + w_2$ ، داریم:

$$\frac{\partial f}{\partial c} \simeq 0.196, \quad \frac{\partial f}{\partial w_2} \simeq 0.196$$

و از $c = a + b$ نتیجه می‌شود:

$$\frac{\partial f}{\partial a} \simeq 0.196, \quad \frac{\partial f}{\partial b} \simeq 0.196$$

اکنون برای ورودی‌های اولیه:

$$\frac{\partial f}{\partial w_0} = \frac{\partial f}{\partial a} \frac{\partial a}{\partial w_0} = 0.196x_0 = -0.196$$

$$\frac{\partial f}{\partial x_0} = \frac{\partial f}{\partial a} \frac{\partial a}{\partial x_0} = 0.196w_0 = 0.392$$

$$\frac{\partial f}{\partial w_1} = \frac{\partial f}{\partial b} \frac{\partial b}{\partial w_1} = 0.196x_1 = -0.392$$

$$\frac{\partial f}{\partial x_1} = \frac{\partial f}{\partial b} \frac{\partial b}{\partial x_1} = 0.196w_1 = -0.588$$

در نتیجه:

$$\frac{\partial f}{\partial w_0} \simeq -0.196, \quad \frac{\partial f}{\partial x_0} \simeq 0.392, \quad \frac{\partial f}{\partial w_1} \simeq -0.392, \quad \frac{\partial f}{\partial x_1} \simeq -0.588, \quad \frac{\partial f}{\partial w_2} \simeq 0.196$$

سؤال پنجم

الف) در رگرسیون لجستیک، خروجی مدل به صورت زیر است:

$$\hat{y} = \sigma(w^T x)$$

پس خروجی مدل یک احتمال است. برای همین، در مسائل دسته‌بندی دودویی معمولاً تابع Binary Cross Entropy نسبت به SSE ترجیح داده می‌شود. تابع SSE به صورت زیر است:

$$E_{SSE} = (y - \sigma(z))^2$$

که در آن:

$$z = w^T x$$

اگر از SSE استفاده کنیم، گرادیان آن شامل مشتق سیگموید می‌شود:

$$\sigma'(z) = \sigma(z)(1 - \sigma(z))$$

وقتی خروجی سیگموید به ۰ یا ۱ نزدیک شود، مقدار $\sigma'(z)$ خیلی کوچک می‌شود. در نتیجه حتی اگر مدل اشتباه کرده باشد، گرادیان کوچک می‌شود و وزن‌ها خیلی کم تغییر می‌کنند.

اما Binary Cross Entropy با خروجی احتمالی مدل سازگارتر است و گرادیان مناسب‌تری برای آموزش می‌دهد. بنابراین برای رگرسیون لجستیک، BCE انتخاب بهتری نسبت به SSE است.

ب)

$$J(w) = \sum_{i=1}^n [-y^{(i)} \log(\sigma(w^T x^{(i)})) - (1 - y^{(i)}) \log(1 - \sigma(w^T x^{(i)}))]$$

برای نمونه‌ی i ام داریم:

$$z^{(i)} = w^T x^{(i)}$$

$$\hat{y}^{(i)} = \sigma(z^{(i)})$$

برای محاسبه‌ی گرادیان، از قاعده‌ی زنجیره‌ای استفاده می‌کنیم:

$$\frac{\partial J}{\partial w} = \frac{\partial J}{\partial \sigma(z)} \frac{\partial \sigma(z)}{\partial z} \frac{\partial z}{\partial w}$$

برای یک نمونه داریم:

$$\frac{\partial J}{\partial \sigma(z)} = \frac{-y}{\sigma(z)} + \frac{1-y}{1-\sigma(z)}$$

پس:

$$\frac{\partial J}{\partial \sigma(z)} = \frac{\sigma(z) - y}{\sigma(z)(1 - \sigma(z))}$$

همچنین:

$$\frac{\partial \sigma(z)}{\partial z} = \sigma(z)(1 - \sigma(z))$$

و:

$$\frac{\partial z}{\partial w} = x$$

بنابراین برای یک نمونه داریم:

$$\frac{\partial J}{\partial w} = \frac{\sigma(z) - y}{\sigma(z)(1 - \sigma(z))} \times \sigma(z)(1 - \sigma(z)) \times x$$

$$\frac{\partial J}{\partial w} = (\sigma(z) - y)x$$

پس برای کل داده‌ها:

$$\nabla_w J(w) = \frac{1}{n} \sum_{i=1}^n (\sigma(w^T x^{(i)}) - y^{(i)}) x^{(i)}$$

ج) در SGD در هر مرحله فقط از یک نمونه استفاده می‌کنیم.

برای نمونه‌ی آموزشی زیر:

$$(x^{(i)}, y^{(i)})$$

ابتدا خروجی مدل را حساب می‌کنیم:

$$\hat{y}^{(i)} = \sigma(w^T x^{(i)})$$

گرایان برای همین نمونه برابر است با:

$$\nabla_w J^{(i)} = (\hat{y}^{(i)} - y^{(i)}) x^{(i)}$$

پس قاعده‌ی به‌روزرسانی وزن‌ها به صورت زیر است:

$$w \leftarrow w - \eta \nabla_w J^{(i)}$$

بنابراین:

$$w \leftarrow w - \eta (\sigma(w^T x^{(i)}) - y^{(i)}) x^{(i)}$$

که در آن η نرخ یادگیری است.

(د) اگر مسئله به جای دو کلاس، سه کلاس داشته باشد، دیگر از یک خروجی Sigmoid استفاده نمی‌کنیم. در این حالت برای هر کلاس یک خروجی جدا داریم.

برچسب‌ها را به صورت One-Hot Encoding می‌نویسیم. برای مثال:

$$y = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} \text{ کلاس اول:}$$

$$y = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \text{ کلاس دوم:}$$

$$y = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \text{ کلاس سوم:}$$

برای هر کلاس یک بردار وزن جدا داریم و امتیاز کلاس c را به صورت زیر حساب می‌کنیم:

$$z_c = w_c^T x$$

برای تبدیل این امتیازها به احتمال، از تابع Softmax استفاده می‌کنیم:

$$\hat{y}_c = \frac{e^{z_c}}{\sum_{j=1}^3 e^{z_j}}$$

پیش‌بینی مدل، کلاسی است که بیشترین احتمال را دارد:

$$\hat{c} = \arg \max_c \hat{y}_c$$

تابع loss نیز به تابع زیر تغییر می‌کند:

$$L_{CE} = - \sum_{c=1}^3 y_c \log(\hat{y}_c)$$

پس برای کل داده‌ها داریم:

$$J(W) = - \frac{1}{n} \sum_{i=1}^n \sum_{c=1}^3 y_c^{(i)} \log(\hat{y}_c^{(i)})$$

در فرایند آموزش، اگر پیش‌بینی مدل درست باشد، یعنی:

$$\hat{c} = c$$

نیازی به تغییر خاصی در جهت اصلاح کلاس‌ها نیست، چون مدل نمونه را درست تشخیص داده است.

اما اگر پیش‌بینی اشتباه باشد، یعنی:

$$\hat{c} \neq c$$

باید وزن‌های مربوط به کلاس درست را تقویت کنیم و وزن‌های مربوط به کلاس اشتباه را کاهش دهیم. به صورت شهودی داریم:

$$w_c \leftarrow w_c + \eta x$$

$$w_{\hat{c}} \leftarrow w_{\hat{c}} - \eta x$$

یعنی وزن کلاس واقعی به سمت نمونه نزدیک‌تر می‌شود و وزن کلاسی که اشتباه انتخاب شده بود، از نمونه دورتر می‌شود. پس فرایند آموزش شبیه حالت دودویی است، اما این بار به جای یک بردار وزن، برای هر کلاس یک بردار وزن جدا داریم و مدل احتمال هر کلاس را جداگانه محاسبه می‌کند.

سؤال ششم

الف) مدل پرسپترون به صورت زیر است:

$$\hat{y} = \text{sign}(w_0 f_0 + w_1 f_1 + w_2 f_2)$$

که در آن:

$$f_0 = 1, \quad \eta = 1$$

بردار وزن اولیه:

$$w = (w_0, w_1, w_2) = (0, 0, 0)$$

آپدیت پرسپترون:

$$w \leftarrow w + \eta y f$$

برای داده‌ی A :

$$f_A = (1, 2, 1), \quad y_A = +1$$

$$w \cdot f_A = 0$$

$$\hat{y}_A = \text{sign}(0) = +1$$

چون $\hat{y}_A = y_A$ ، آپدیت نداریم:

$$w = (0, 0, 0)$$

برای داده‌ی B :

$$f_B = (1, -1, 2), \quad y_B = +1$$

$$w \cdot f_B = 0$$

$$\hat{y}_B = \text{sign}(0) = +1$$

چون $\hat{y}_B = y_B$ ، آپدیت نداریم:

$$w = (0, 0, 0)$$

برای داده‌ی C :

$$f_C = (1, 1, -2), \quad y_C = -1$$

$$w \cdot f_C = 0$$

$$\hat{y}_C = \text{sign}(0) = +1$$

چون $\hat{y}_C \neq y_C$ ، وزن‌ها را آپدیت می‌کنیم:

$$w \leftarrow (0, 0, 0) + 1(-1)(1, 1, -2)$$

$$w = (-1, -1, 2)$$

برای داده‌ی D :

$$f_D = (1, -2, -1), \quad y_D = -1$$

$$w \cdot f_D = (-1)(1) + (-1)(-2) + 2(-1)$$

$$w \cdot f_D = -1 + 2 - 2 = -1$$

$$\hat{y}_D = \text{sign}(-1) = -1$$

چون $\hat{y}_D = y_D$ ، آپدیت نداریم:

$$w = (-1, -1, 2)$$

پس بعد از یک بار عبور از همه‌ی داده‌ها داریم:

$$w = (-1, -1, 2)$$

(ب) با وزن به‌دست‌آمده داریم:

$$w = (-1, -1, 2)$$

برای داده‌ی A :

$$w \cdot f_A = (-1)(1) + (-1)(2) + 2(1)$$

$$w \cdot f_A = -1 - 2 + 2 = -1$$

$$\hat{y}_A = -1$$

اما:

$$y_A = +1$$

پس داده‌ی A اشتباه دسته‌بندی می‌شود.

برای داده‌ی B :

$$w \cdot f_B = (-1)(1) + (-1)(-1) + 2(2)$$

$$w \cdot f_B = -1 + 1 + 4 = 4$$

$$\hat{y}_B = +1$$

برای داده‌ی C :

$$w \cdot f_C = (-1)(1) + (-1)(1) + 2(-2)$$

$$w \cdot f_C = -1 - 1 - 4 = -6$$

$$\hat{y}_C = -1$$

برای داده‌ی D :

$$w \cdot f_D = (-1)(1) + (-1)(-2) + 2(-1)$$

$$w \cdot f_D = -1 + 2 - 2 = -1$$

$$\hat{y}_D = -1$$

پس با وزن‌های بخش الف، همه‌ی داده‌ها درست دسته‌بندی نمی‌شوند:

اشتباه دسته‌بندی می‌شود. A خیر، داده‌ی

اما این لزوماً به معنی خطی جدا ناپذیر بودن داده‌ها نیست؛ چون پرسپترون ممکن است با تکرارهای بیشتر به وزن مناسب برسد.

(ج) برای بررسی خطی جداپذیر بودن داده‌ها، باید ببینیم آیا بردار وزنی وجود دارد که داده‌های مثبت را در سمت مثبت و داده‌های منفی را در سمت منفی مرز تصمیم قرار دهد یا نه.

مرز تصمیم را به صورت زیر در نظر می‌گیریم:

$$w_0 + w_1 f_1 + w_2 f_2 = 0$$

برای داده‌های مثبت A و B باید داشته باشیم:

$$w_0 + w_1 f_{1A} + w_2 f_{2A} \geq 0$$

$$w_0 + w_1 f_{1B} + w_2 f_{2B} \geq 0$$

پس:

$$w_0 + 2w_1 + w_2 \geq 0$$

$$w_0 - w_1 + 2w_2 \geq 0$$

دو نامساوی بالا را با هم جمع می‌کنیم:

$$2w_0 + w_1 + 3w_2 \geq 0$$

برای داده‌های منفی C و D باید داشته باشیم:

$$w_0 + w_1 f_{1C} + w_2 f_{2C} < 0$$

$$w_0 + w_1 f_{1D} + w_2 f_{2D} < 0$$

پس:

$$w_0 + w_1 - 2w_2 < 0$$

$$w_0 - 2w_1 - w_2 < 0$$

دو نامساوی بالا را با هم جمع می‌کنیم:

$$2w_0 - w_1 - 3w_2 < 0$$

حالا می‌توانیم یک انتخاب ساده برای وزن‌ها پیدا کنیم. مثلاً اگر بگیریم:

$$w_0 = 0, \quad w_1 = 1, \quad w_2 = 3$$

آنگاه برای داده‌های مثبت داریم:

$$A: \quad w_0 + 2w_1 + w_2 = 0 + 2 + 3 = 5 > 0$$

$$B: \quad w_0 - w_1 + 2w_2 = 0 - 1 + 6 = 5 > 0$$

و برای داده‌های منفی داریم:

$$C: \quad w_0 + w_1 - 2w_2 = 0 + 1 - 6 = -5 < 0$$

$$D : \quad w_0 - 2w_1 - w_2 = 0 - 2 - 3 = -5 < 0$$

پس این انتخاب همه‌ی داده‌ها را درست جدا می‌کند.
بنابراین بردار وزن زیر مناسب است:

$$w = (0, 1, 3)$$

و مرز تصمیم برابر است با:

$$f_1 + 3f_2 = 0$$

در نتیجه داده‌ها خطی جداپذیر هستند:

داده‌ها خطی جداپذیر هستند.

سؤال هفتم

الف) برای محدب بودن با شرط نابرابری Jensen باید برای هر x, y از دامنه و هر $\lambda \in [0, 1]$ داشته باشیم:

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$$

تابع اول:

$$f(x) = \sqrt{x} \quad x \in [0, \infty)$$

برای بررسی، یک مثال نقض می‌زنیم. فرض می‌کنیم:

$$x = 0, \quad y = 4, \quad \lambda = \frac{1}{2}$$

سمت چپ نامساوی:

$$f(\lambda x + (1 - \lambda)y) = f\left(\frac{1}{2}(0) + \frac{1}{2}(4)\right) = f(2) = \sqrt{2}$$

سمت راست نامساوی:

$$\lambda f(x) + (1 - \lambda)f(y) = \frac{1}{2}f(0) + \frac{1}{2}f(4)$$

$$= \frac{1}{2}(0) + \frac{1}{2}(2) = 1$$

اما داریم:

$$\sqrt{2} > 1$$

پس شرط Jensen برای محدب بودن برقرار نیست. بنابراین:

$$f(x) = \sqrt{x} \text{ روی } [0, \infty) \text{ محدب نیست.}$$

تابع دوم:

$$f(x) = x^2 \quad x \in R$$

باید نشان دهیم:

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$$

یعنی:

$$(\lambda x + (1 - \lambda)y)^2 \leq \lambda x^2 + (1 - \lambda)y^2$$

اختلاف سمت راست و سمت چپ را حساب می‌کنیم:

$$\lambda x^2 + (1 - \lambda)y^2 - (\lambda x + (1 - \lambda)y)^2$$

$$\lambda x^2 + (1 - \lambda)y^2 - (\lambda^2 x^2 + 2\lambda(1 - \lambda)xy + (1 - \lambda)^2 y^2)$$

$$= \lambda(1 - \lambda)x^2 - 2\lambda(1 - \lambda)xy + \lambda(1 - \lambda)y^2$$

$$= \lambda(1 - \lambda)(x - y)^2$$

چون:

$$\lambda \in [0, 1]$$

پس:

$$\lambda(1 - \lambda) \geq 0$$

و همچنین:

$$(x - y)^2 \geq 0$$

در نتیجه:

$$\lambda(1 - \lambda)(x - y)^2 \geq 0$$

پس:

$$(\lambda x + (1 - \lambda)y)^2 \leq \lambda x^2 + (1 - \lambda)y^2$$

بنابراین شرط Jensen برقرار است و داریم:

$$\boxed{f(x) = x^2 \text{ روی } R \text{ محدب است.}}$$

ب) برای بررسی با مشتق دوم، اگر روی دامنه داشته باشیم:

$$f''(x) \geq 0$$

آنگاه تابع روی آن دامنه محدب است.

تابع اول:

$$f(x) = -\log(x) \quad x \in (0, \infty)$$

مشتق اول:

$$f'(x) = -\frac{1}{x}$$

مشتق دوم:

$$f''(x) = \frac{1}{x^2}$$

چون دامنه تابع برابر $(0, \infty)$ است، داریم:

$$x > 0$$

پس:

$$\frac{1}{x^2} > 0$$

بنابراین مشتق دوم روی کل دامنه مثبت است. پس:

$$\boxed{f(x) = -\log(x) \text{ روی } (0, \infty) \text{ محدب است.}}$$

تابع دوم:

$$f(x) = x^4 - 2x^2 \quad x \in R$$

مشتق اول:

$$f'(x) = 4x^3 - 4x$$

مشتق دوم:

$$f''(x) = 12x^2 - 4$$

برای اینکه تابع روی کل اعداد حقیقی محدب باشد، باید برای همه‌ی x ها داشته باشیم:

$$f''(x) \geq 0$$

اما اگر $x = 0$ قرار دهیم:

$$f''(0) = 12(0)^2 - 4 = -4$$

چون:

$$-4 < 0$$

پس مشتق دوم همیشه نامنفی نیست. بنابراین تابع روی کل R محدب نیست:

$f(x) = x^4 - 2x^2$ روی R محدب نیست.

سؤال هشتم

آ ماتریس ورودی با padding برابر ۱ به صورت زیر می‌شود:

$$X_p = \begin{bmatrix} 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 2 & 0 & 1 & 0 \\ 0 & 3 & 1 & 2 & 1 & 0 \\ 0 & 0 & 1 & 3 & 1 & 0 \\ 0 & 2 & 3 & 1 & 2 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

اندازه‌ی خروجی برابر است با:

$$\frac{4 + 2(1) - 2}{1} + 1 = 5$$

پس خروجی یک ماتریس 5×5 است.

فیلتر داده‌شده:

$$K = \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix}$$

$$Y = \begin{bmatrix} 1 & 2 & 0 & 1 & 0 \\ 2 & 0 & 4 & 0 & 1 \\ -3 & 3 & 2 & 2 & 1 \\ 2 & 2 & -1 & 4 & 1 \\ -2 & -1 & 2 & -1 & 2 \end{bmatrix}$$

ب) ماتریس‌های داده‌شده به صورت زیر هستند:

$$Q = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}, \quad K = \begin{bmatrix} 0 & 1 \\ 1 & 1 \end{bmatrix}, \quad V = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$$

ابتدا ماتریس امتیازها را حساب می‌کنیم:

$$S = QK^T$$

$$K^T = \begin{bmatrix} 0 & 1 \\ 1 & 1 \end{bmatrix}$$

$$S = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 0 & 1 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 3 \\ 1 & 1 \end{bmatrix}$$

چون $d = 2$ ، در حالت Scaled Dot-Product Attention داریم:

$$S_{\text{scaled}} = \frac{S}{\sqrt{2}}$$

$$S_{\text{scaled}} = \frac{1}{\sqrt{2}} \begin{bmatrix} 2 & 3 \\ 1 & 1 \end{bmatrix} \approx \begin{bmatrix} 1.414 & 2.121 \\ 0.707 & 0.707 \end{bmatrix}$$

حالا روی هر سطر softmax می‌گیریم:

$$A = \text{softmax}(S_{\text{scaled}})$$

برای سطر اول:

$$\text{softmax}([1.414, 2.121]) \approx [0.33, 0.67]$$

برای سطر دوم:

$$\text{softmax}([0.707, 0.707]) = [0.5, 0.5]$$

پس:

$$A \approx \begin{bmatrix} 0.33 & 0.67 \\ 0.5 & 0.5 \end{bmatrix}$$

خروجی نهایی توجه برابر است با:

$$\text{Output} = AV$$

$$\text{Output} = \begin{bmatrix} 0.33 & 0.67 \\ 0.5 & 0.5 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$$

$$\text{Output} \approx \begin{bmatrix} 1.33 & 2.34 \\ 1.5 & 2 \end{bmatrix}$$