

به نام خدا



کسری شیخی
۴۰۳۱۱۰۵۹۶

هوش مصنوعی
بهار ۱۴۰۵
استاد: آرش ماری اوریاد

دانشکده مهندسی کامپیوتر

پاسخ تمرین سری پنجم - یادگیری تقویتی

سؤال اول

(آ) درست

همگرایی سیاست تنها به $\arg\max$ مقادیر Q در هر حالت بستگی دارد، نه به مقدار دقیق آن‌ها. بنابراین ممکن است پس از چند ایتريشن، $\arg\max$ در همه‌ی حالت‌ها ثابت شود و سیاست حریصانه دیگر تغییر نکند، در حالی که V هنوز به مقدار دقیق V^* نرسیده و به‌روزرسانی آن ادامه دارد.

(ب) نادرست

Q-learning یک الگوریتم off-policy است؛ یعنی مقادیر بهینه‌ی Q را می‌تواند مستقل از اینکه کنش‌های واقعاً انتخاب‌شده طبق سیاست رفتاری بهینه باشند یا نه، یاد بگیرد. شرط کافی همگرایی، بازدید کافی از همه‌ی زوج‌های (s, a) است، نه بهینه بودن سیاست رفتاری.

(ج) درست

در Value Iteration هر ایتريشن شامل به‌روزرسانی همه‌ی حالت‌ها با پیچیدگی $O(|S|^2|A|)$ است. در Policy Iteration هر ایتريشن شامل ارزیابی سیاست با پیچیدگی $O(|S|^3)$ و بهبود سیاست با پیچیدگی $O(|S|^2|A|)$ است. اگر $|A| \approx |S|$ ، هر دو از مرتبه‌ی $O(|S|^3)$ می‌شوند، پس پیچیدگی هر ایتريشن تقریباً برابر خواهد بود.

(د) نادرست

اگر به همه‌ی پاداش‌ها یک ثابت c اضافه کنیم، سیاست بهینه لزوماً ثابت نمی‌ماند. دلیلش این است که اگر MDP حالت terminal داشته باشد، سیاست‌هایی که دیرتر به حالت پایانی می‌رسند تعداد پاداش‌های بیشتری می‌گیرند؛ پس مقدار اضافه‌شده برای همه‌ی سیاست‌ها یکسان نیست.

البته اگر افق نامحدود باشد و پایان اپیزود در کار نباشد، در این حالت مقدار اضافه‌شده برای همه‌ی سیاست‌ها برابر با

$$\frac{c}{1 - \gamma}$$

می‌شود و آنگاه گزاره درست خواهد بود. اما در حالت کلی گزاره نادرست است.

(ه) نادرست

مقدار γ میزان اهمیت پاداش‌های آینده نسبت به پاداش‌های نزدیک را مشخص می‌کند. پس اگر γ عوض شود، ممکن است کنش بهینه هم عوض شود.

برای مثال یک MDP را در نظر بگیرید که از حالت شروع s دو کنش داریم:

و پایان 5 دریافت پاداش a_1 :

و پایان 10 و سپس در گام بعدی پاداش 0 ابتدا پاداش a_2 :

ارزش کنش اول برابر است با:

$$Q(s, a_1) = 5$$

و ارزش کنش دوم برابر است با:

$$Q(s, a_2) = 10\gamma$$

اگر $\gamma = 0.4$ باشد، داریم:

$$Q(s, a_2) = 4 < 5$$

پس کنش a_1 بهتر است. اما اگر $\gamma = 0.9$ باشد، داریم:

$$Q(s, a_2) = 9 > 5$$

پس کنش a_2 بهتر می‌شود. بنابراین دو MDP که فقط در مقدار γ فرق دارند، لزوماً سیاست بهینه‌ی یکسانی ندارند.

(و) درست

در افق محدود (finite horizon)، ارزش هر کنش به تعداد گام‌های باقی‌مانده تا پایان افق بستگی دارد. بنابراین حتی برای یک حالت ثابت s ، سیاست بهینه بسته به این‌که چند گام تا پایان مانده می‌تواند فرق کند؛ یعنی سیاست بهینه non-stationary است، برخلاف MDP با افق نامحدود که سیاست بهینه stationary است.

(آ) تفاوت on-policy RL و off-policy RL: در روش‌های on-policy، عامل ارزش‌سیاستی را یاد می‌گیرد که برای تولید تجربه از همان استفاده می‌کند؛ یعنی سیاست رفتاری (behavior policy) و سیاست هدف (target policy) یکسان هستند، مانند SARSA. در روش‌های off-policy، سیاست تولید تجربه می‌تواند با سیاستی که عامل قصد یادگیری ارزش آن را دارد متفاوت باشد، مانند Q-learning که Q^* را یاد می‌گیرد، حتی اگر کنش‌ها با سیاستی مثل ϵ -greedy انتخاب شده باشند.

(ب) تفاوت model-based RL و model-free RL: در model-based RL، عامل مدل محیط یعنی توابع گذار $T(s' | s, a)$ و پاداش $R(s, a, s')$ را از قبل می‌داند یا از تجربه تخمین می‌زند و بعد با استفاده از این مدل برنامه‌ریزی می‌کند. در model-free RL، عامل ارزش‌سیاستی را یاد می‌گیرد و فقط از تجربه برای تخمین استفاده می‌کند.

free RL، عامل بدون ساختن مدل صریحی از محیط، مستقیماً از تعامل با محیط تابع ارزش یا سیاست را یاد می‌گیرد، مانند Monte Carlo و SARSA، Q-learning.

سؤال دوم

آ) رابطه به روزرسانی در Value Iteration برابر است با:

$$V_{k+1}(s) = \max_a \sum_{s'} T(s'|s, a) (R(s, a, s') + \gamma V_k(s')), \quad \gamma = 0.9$$

در ابتدا:

$$V_0(s) = 0$$

حالت‌های terminal مقدار صفر دارند:

$$V(3, 1) = 0, \quad V(3, 2) = 0$$

مرحله اول:

فقط دو حالت می‌توانند در یک حرکت به خانه با پاداش مثبت برسند:

$$V_1(2, 2) = 0.9(10) = 9, \quad V_1(3, 3) = 0.9(10) = 9$$

پس:

$$V_1(1, 1) = 0, \quad V_1(1, 2) = 0, \quad V_1(1, 3) = 0, \quad V_1(2, 1) = 0$$

$$V_1(2, 2) = 9, \quad V_1(2, 3) = 0, \quad V_1(3, 3) = 9$$

مرحله دوم:

$$V_2(1, 1) = 0$$

$$V_2(1, 2) = 0.9 (0.9V_1(2, 2)) = 0.9(0.9 \times 9) = 7.29$$

$$V_2(1, 3) = 0$$

$$V_2(2, 1) = 0.9 (0.9V_1(2, 2)) + 0.05(-10) = 7.29 - 0.5 = 6.79$$

$$V_2(2, 2) = 0.9(10) = 9$$

$$V_2(2, 3) = 0.9 (0.9V_1(3, 3)) + 0.05 (0.9V_1(2, 2)) = 7.29 + 0.405 = 7.695$$

$$V_2(3, 3) = 0.9(10) + 0.05 (0.9V_1(3, 3)) = 9 + 0.405 = 9.405$$

پس:

$$V_2(1, 1) = 0, \quad V_2(1, 2) = 7.29, \quad V_2(1, 3) = 0$$

$$V_2(2, 1) = 6.79, \quad V_2(2, 2) = 9, \quad V_2(2, 3) = 7.695, \quad V_2(3, 3) = 9.405$$

ب) در TD Learning داریم:

$$V(s) \leftarrow V(s) + \alpha (r + \gamma V(s') - V(s)), \quad \alpha = 0.1, \quad \gamma = 0.9$$

در ابتدا همه مقدارها صفر هستند.

مسیر اول:

$$(1, 1) \rightarrow (1, 2) \rightarrow (1, 3)$$

در این مسیر reward ای دریافت نمی شود:

$$V(1,1) \leftarrow 0 + 0.1 (0 + 0.9V(1,2) - 0) = 0$$

$$V(1,2) \leftarrow 0 + 0.1 (0 + 0.9V(1,3) - 0) = 0$$

مسیر دوم:

$$(1,1) \rightarrow (1,2) \rightarrow (2,2) \rightarrow (2,3)$$

باز هم reward ای دریافت نمی شود:

$$V(1,1) \leftarrow 0 + 0.1 (0 + 0.9V(1,2) - 0) = 0$$

$$V(1,2) \leftarrow 0 + 0.1 (0 + 0.9V(2,2) - 0) = 0$$

$$V(2,2) \leftarrow 0 + 0.1 (0 + 0.9V(2,3) - 0) = 0$$

پس:

$$V(1,1) = 0, \quad V(1,2) = 0, \quad V(2,2) = 0$$

و بقیه مقادارها نیز صفر می مانند.

ج) در SARSA داریم:

$$Q(s,a) \leftarrow Q(s,a) + \alpha (r + \gamma Q(s',a') - Q(s,a)), \quad \alpha = 0.1, \quad \gamma = 0.9$$

در ابتدا:

$$Q_0(s,a) = 0$$

کنش راست را با a_R نشان می دهیم.

مسیر اول:

$$(1,1) \rightarrow (1,2) \rightarrow (1,3)$$

$$Q((1,1), a_R) \leftarrow 0 + 0.1 (0 + 0.9Q((1,2), a_R) - 0) = 0$$

$$Q((1,2), a_R) \leftarrow 0 + 0.1 (0 + 0.9Q((1,3), a_R) - 0) = 0$$

مسیر دوم:

$$(1,1) \rightarrow (1,2) \rightarrow (2,2) \rightarrow (2,3)$$

$$Q((1,1), a_R) \leftarrow 0 + 0.1 (0 + 0.9Q((1,2), a_R) - 0) = 0$$

$$Q((1,2), a_R) \leftarrow 0 + 0.1 (0 + 0.9Q((2,2), a_R) - 0) = 0$$

$$Q((2,2), a_R) \leftarrow 0 + 0.1 (0 + 0.9Q((2,3), a_R) - 0) = 0$$

پس:

$$Q((1,1), a_R) = 0, \quad Q((1,2), a_R) = 0, \quad Q((2,2), a_R) = 0$$

د) در Q-learning داریم:

$$Q(s,a) \leftarrow Q(s,a) + \alpha \left(r + \gamma \max_{a'} Q(s',a') - Q(s,a) \right)$$

تفاوتش با SARSA این است که در SARSA از action واقعی بعدی استفاده می‌شود، ولی در Q-learning بهترین action ممکن در حالت بعدی را می‌گیریم.

چون مقدار اولیه همه Q ها صفر است و در این دو مسیر reward غیرصفری نداریم، همه آپدیت‌ها صفر می‌شوند:

$$Q((1, 1), a_R) = 0, \quad Q((1, 2), a_R) = 0, \quad Q((2, 2), a_R) = 0$$

پس در این مثال مقدار عددی SARSA و Q-learning یکی می‌شود، ولی از نظر مفهومی یکی نیستند.

ه) در Direct Evaluation برای هر حالتی که در مسیر دیده شده، return تخفیف‌خورده را حساب می‌کنیم:

$$G_t = \sum_{k=0}^{T-t-1} \gamma^k r_{t+k+1}, \quad \gamma = 0.9$$

مسیر اول:

$$(1, 1) \rightarrow (1, 2) \rightarrow (1, 3)$$

چون reward نداریم:

$$G(1, 1) = 0, \quad G(1, 2) = 0$$

مسیر دوم:

$$(1, 1) \rightarrow (1, 2) \rightarrow (2, 2) \rightarrow (2, 3)$$

باز هم reward نداریم:

$$G(1, 1) = 0, \quad G(1, 2) = 0, \quad G(2, 2) = 0$$

پس:

$$\hat{V}(1, 1) = \frac{0+0}{2} = 0$$

$$\hat{V}(1, 2) = \frac{0+0}{2} = 0$$

$$\hat{V}(2, 2) = 0$$

حالت‌های $(1, 3)$ و $(2, 3)$ انتهای مسیرهای مشاهده‌شده هستند، پس return قابل‌استفاده‌ای برایشان نداریم. حالت‌هایی مثل $(2, 1)$ و $(3, 3)$ هم دیده نشده‌اند.

از نظر sample efficiency، روش Direct Evaluation ضعیف‌تر از TD Learning است، چون باید ادامه مسیر را ببیند. ولی TD Learning با هر گام می‌تواند آپدیت انجام دهد و اطلاعات را سریع‌تر پخش کند.

سؤال سوم

آ) می‌خواهیم بررسی کنیم آیا برای سیاست π_3 داریم:

$$V_3 = \frac{1}{2}V_1 + \frac{1}{2}V_2$$

پاسخ منفی است. برای رد این گزاره یک مثال نقض می‌زنیم.

یک MDP با یک حالت غیرپایانی s و یک حالت پایانی t در نظر می‌گیریم. در حالت s دو کنش a و b داریم:

$$a : \quad s \rightarrow s, \quad r = 0$$

$$b : \quad s \rightarrow t, \quad r = 1$$

حالت t پایانی است و ارزش آن صفر است. ضریب تخفیف را هم برابر $\gamma = 0.9$ در نظر می‌گیریم.

سیاست اول π_1 همیشه کنش a را انتخاب می‌کند. پس عامل همیشه در حالت s می‌ماند و هیچ پاداشی نمی‌گیرد. بنابراین:

$$V_1(s) = 0$$

سیاست دوم π_2 همیشه کنش b را انتخاب می‌کند. پس عامل همان اول پاداش 1 می‌گیرد و وارد حالت پایانی می‌شود. بنابراین:

$$V_2(s) = 1$$

اگر رابطه‌ی داده‌شده درست بود، باید می‌داشتیم:

$$\frac{1}{2}V_1(s) + \frac{1}{2}V_2(s) = \frac{1}{2}(0) + \frac{1}{2}(1) = \frac{1}{2}$$

حالا سیاست π_3 را بررسی می‌کنیم. این سیاست در هر بار حضور در حالت s ، با احتمال $\frac{1}{2}$ کنش a و با احتمال $\frac{1}{2}$ کنش b را انتخاب می‌کند.

پس معادله بلمن برای $V_3(s)$ به صورت زیر است:

$$V_3(s) = \frac{1}{2}(0 + \gamma V_3(s)) + \frac{1}{2}(1 + \gamma V_3(t))$$

چون t حالت پایانی است، داریم:

$$V_3(t) = 0$$

پس:

$$V_3(s) = \frac{1}{2}\gamma V_3(s) + \frac{1}{2}$$

با جایگذاری $\gamma = 0.9$:

$$V_3(s) = 0.45V_3(s) + 0.5$$

$$V_3(s) - 0.45V_3(s) = 0.5$$

$$0.55V_3(s) = 0.5$$

$$V_3(s) = \frac{0.5}{0.55}$$

$$V_3(s) = \frac{10}{11}$$

اما از طرف دیگر داشتیم:

$$\frac{1}{2}V_1(s) + \frac{1}{2}V_2(s) = \frac{1}{2}$$

پس:

$$V_3(s) = \frac{10}{11} \neq \frac{1}{2} = \frac{1}{2}V_1(s) + \frac{1}{2}V_2(s)$$

بنابراین نمی‌توان گفت تابع ارزش سیاست مخلوط، حتماً برابر با میانگین تابع ارزش دو سیاست اولیه است. دلیلش هم این است که سیاست جدید در هر گام دوباره تصمیم تصادفی می‌گیرد و این باعث می‌شود مسیرهایی ساخته شوند که رفتارشان صرفاً میانگین دو سیاست قبلی نیست.

سؤال چهارم

آ در این سؤال ضریب تخفیف برابر است با:

$$\gamma = 0.5$$

سیاست اولیه π_1 در هر حالت، بین دو کنش x و y با احتمال برابر انتخاب می‌کند. همچنین مقدار اولیه‌ی تابع ارزش برای همه‌ی حالت‌ها برابر است با:

$$V_1(A) = V_1(B) = V_1(C) = 2$$

برای اجرای یک مرحله از ارزیابی سیاست، مقدار هر حالت را با استفاده از مقدارهای قبلی حساب می‌کنیم.

حالت A :

اگر کنش x را انتخاب کنیم، با پاداش 4 به حالت B می‌رویم. پس:

$$Q_1(A, x) = 4 + \gamma V_1(B) = 4 + 0.5(2) = 5$$

اگر کنش y را انتخاب کنیم، با پاداش 2 به حالت C می‌رویم. پس:

$$Q_1(A, y) = 2 + \gamma V_1(C) = 2 + 0.5(2) = 3$$

چون سیاست تصادفی است، مقدار جدید A برابر میانگین این دو مقدار می‌شود:

$$V_2(A) = \frac{1}{2}Q_1(A, x) + \frac{1}{2}Q_1(A, y) = \frac{1}{2}(5) + \frac{1}{2}(3) = 4$$

حالت B :

اگر کنش x را انتخاب کنیم، با پاداش 2 به حالت C می‌رویم:

$$Q_1(B, x) = 2 + \gamma V_1(C) = 2 + 0.5(2) = 3$$

اگر کنش y را انتخاب کنیم، با پاداش 0 به حالت A می‌رویم:

$$Q_1(B, y) = 0 + \gamma V_1(A) = 0 + 0.5(2) = 1$$

پس:

$$V_2(B) = \frac{1}{2}Q_1(B, x) + \frac{1}{2}Q_1(B, y) = \frac{1}{2}(3) + \frac{1}{2}(1) = 2$$

حالت C :

اگر کنش y را انتخاب کنیم، با پاداش 1 به حالت B می‌رویم:

$$Q_1(C, y) = 1 + \gamma V_1(B) = 1 + 0.5(2) = 2$$

اگر کنش x را انتخاب کنیم، پاداش ۸ می‌گیریم و سپس با احتمال $\frac{1}{4}$ به A می‌رویم و با احتمال $\frac{3}{4}$ در C می‌مانیم. بنابراین:

$$Q_1(C, x) = 8 + \gamma \left(\frac{1}{4} V_1(A) + \frac{3}{4} V_1(C) \right)$$

$$Q_1(C, x) = 8 + 0.5 \left(\frac{1}{4}(2) + \frac{3}{4}(2) \right) = 8 + 0.5(2) = 9$$

پس:

$$V_2(C) = \frac{1}{2} Q_1(C, x) + \frac{1}{2} Q_1(C, y) = \frac{1}{2}(9) + \frac{1}{2}(2) = 5.5$$

در نتیجه بعد از یک مرحله ارزیابی سیاست داریم:

$$\boxed{V_2(A) = 4, \quad V_2(B) = 2, \quad V_2(C) = 5.5}$$

ب) حالا باید نسبت به تابع ارزش جدید، یعنی V_2 ، سیاست حریصانه‌ی جدید π_2 را پیدا کنیم.

$$V_2(A) = 4, \quad V_2(B) = 2, \quad V_2(C) = 5.5$$

حالت A :

$$Q_2(A, x) = 4 + \gamma V_2(B) = 4 + 0.5(2) = 5$$

$$Q_2(A, y) = 2 + \gamma V_2(C) = 2 + 0.5(5.5) = 4.75$$

چون:

$$Q_2(A, x) > Q_2(A, y)$$

پس:

$$\pi_2(A) = x$$

حالت B :

$$Q_2(B, x) = 2 + \gamma V_2(C) = 2 + 0.5(5.5) = 4.75$$

$$Q_2(B, y) = 0 + \gamma V_2(A) = 0 + 0.5(4) = 2$$

چون:

$$Q_2(B, x) > Q_2(B, y)$$

پس:

$$\pi_2(B) = x$$

حالت C :

$$Q_2(C, y) = 1 + \gamma V_2(B) = 1 + 0.5(2) = 2$$

$$Q_2(C, x) = 8 + \gamma \left(\frac{1}{4} V_2(A) + \frac{3}{4} V_2(C) \right)$$

$$Q_2(C, x) = 8 + 0.5 \left(\frac{1}{4}(4) + \frac{3}{4}(5.5) \right)$$

$$Q_2(C, x) = 8 + 0.5(1 + 4.125) = 8 + 2.5625 = 10.5625$$

چون:

$$Q_2(C, x) > Q_2(C, y)$$

پس:

$$\pi_2(C) = x$$

در نتیجه سیاست حریصانه‌ی جدید برابر است با:

$$\boxed{\pi_2(A) = x, \quad \pi_2(B) = x, \quad \pi_2(C) = x}$$

ج) می‌خواهیم نشان دهیم اگر سیاست π' به صورت حریصانه از روی V^π ساخته شده باشد، آنگاه برای همه‌ی حالت‌ها داریم:

$$V^{\pi'}(s) \geq V^\pi(s)$$

چون π' نسبت به V^π حریصانه است، برای هر حالت s داریم:

$$\pi'(s) = \arg \max_a Q^\pi(s, a)$$

پس:

$$Q^\pi(s, \pi'(s)) = \max_a Q^\pi(s, a)$$

از طرفی کنشی که سیاست π انتخاب می‌کند، یکی از همین کنش‌هاست. بنابراین:

$$Q^\pi(s, \pi'(s)) \geq Q^\pi(s, \pi(s))$$

ولی طبق تعریف تابع ارزش سیاست π داریم:

$$Q^\pi(s, \pi(s)) = V^\pi(s)$$

پس نتیجه می‌شود:

$$Q^\pi(s, \pi'(s)) \geq V^\pi(s)$$

حالا $Q^\pi(s, \pi'(s))$ را با رابطه‌ی بلمن باز می‌کنیم:

$$Q^\pi(s, \pi'(s)) = R(s, \pi'(s)) + \gamma \sum_{s'} P(s'|s, \pi'(s)) V^\pi(s')$$

پس داریم:

$$V^\pi(s) \leq R(s, \pi'(s)) + \gamma \sum_{s'} P(s'|s, \pi'(s)) V^\pi(s')$$

حالا اگر همین نامساوی را برای حالت‌های بعدی هم به صورت تکراری جایگذاری کنیم، سمت راست به ارزش اجرای سیاست π' تبدیل می‌شود. یعنی:

$$V^\pi(s) \leq \mathbb{E}_{\pi'} \left[\sum_{t=0}^{\infty} \gamma^t R_t \mid S_0 = s \right]$$

پس:

$$V^\pi(s) \leq V^{\pi'}(s)$$

بنابراین:

$$\boxed{V^{\pi'}(s) \geq V^\pi(s)}$$

برای بخش دوم، فرض کنیم برای همه‌ی حالت‌ها تساوی برقرار باشد:

$$V^{\pi'}(s) = V^\pi(s)$$

از طرفی چون نسبت به V^π حریصانه ساخته شده است، داریم:

$$T^* V^\pi = T^{\pi'} V^\pi$$

و چون طبق فرض $V^{\pi'} = V^\pi$ ، پس:

$$V^\pi = T^{\pi'} V^\pi$$

بنابراین:

$$V^\pi = T^* V^\pi$$

این یعنی V^π معادله‌ی بهینگی بلمن را ارضا می‌کند. از آن جا که جواب معادله‌ی بهینگی بلمن یکتاست، داریم:

$$V^\pi = V^*$$

پس سیاست π بهینه است. همچنین چون π' نسبت به V^* حریصانه است، π' هم سیاست بهینه خواهد بود. در نتیجه اگر تساوی برای همه‌ی حالت‌ها رخ دهد، سیاست به دست آمده حتماً بهینه است.

$$\boxed{V^{\pi'} = V^\pi \implies V^\pi = V^*}$$

سؤال پنجم

الف) چون کارت‌ها فقط می‌توانند مقدارهای ۲، ۳ و ۴ داشته باشند، از حالت شروع فقط جمع‌های ۵، ۴، ۳، ۲، ۰ قابل رسیدن‌اند. پس فضای حالت برابر است با:

$$S = \{(0, C), (2, C), (3, C), (4, C), (5, C), \text{Done}\}$$

که C یعنی بازی هنوز در جریان است و Done یعنی بازی تمام شده است.

ب) اگر عامل کنش stop را در حالت (n, C) انتخاب کند، بازی تمام می‌شود و پاداش برابر n است:

$$R((n, C), \text{stop}) = n$$

اگر کنش draw را انتخاب کند، پاداش آنی صفر است. اگر جمع جدید کمتر از ۶ باشد، بازی ادامه پیدا می‌کند؛ وگرنه به حالت Done می‌رود و امتیاز نهایی صفر می‌شود:

$$R((n, C), \text{draw}) = 0$$

$$R(\text{Done}, \cdot) = 0$$

ج) برای مقدار بهینه داریم:

$$V^*(s) = \max_a Q^*(s, a)$$

و چون $\gamma = 1$ ، محاسبات از حالت‌های آخر ساده‌تر انجام می‌شود.
برای حالت $(5, C)$:

$$V^*(5, C) = \max\{5, 0\} = 5$$

برای حالت $(4, C)$:

$$V^*(4, C) = \max\{4, 0\} = 4$$

برای حالت $(3, C)$:

$$Q^*((3, C), \text{draw}) = \frac{1}{3}V^*(5, C) + \frac{1}{3}(0) + \frac{1}{3}(0) = \frac{5}{3}$$

$$V^*(3, C) = \max\left\{3, \frac{5}{3}\right\} = 3$$

برای حالت $(2, C)$:

$$Q^*((2, C), \text{draw}) = \frac{1}{3}V^*(4, C) + \frac{1}{3}V^*(5, C) + \frac{1}{3}(0) = \frac{4+5}{3} = 3$$

$$V^*(2, C) = \max\{2, 3\} = 3$$

برای حالت $(0, C)$:

$$Q^*((0, C), \text{draw}) = \frac{1}{3}V^*(2, C) + \frac{1}{3}V^*(3, C) + \frac{1}{3}V^*(4, C) = \frac{3 + 3 + 4}{3} = \frac{10}{3}$$

$$V^*(0, C) = \frac{10}{3}$$

پس مقدارهای نهایی و سیاست بهینه به صورت زیر است:

$$V^*(0, C) = \frac{10}{3}, \quad \pi^*(0, C) = \text{draw}$$

$$V^*(2, C) = 3, \quad \pi^*(2, C) = \text{draw}$$

$$V^*(3, C) = 3, \quad \pi^*(3, C) = \text{stop}$$

$$V^*(4, C) = 4, \quad \pi^*(4, C) = \text{stop}$$

$$V^*(5, C) = 5, \quad \pi^*(5, C) = \text{stop}$$

$$V^*(\text{Done}) = 0$$

(د) در این بخش فرض می‌کنیم در تمامی نمونه‌ها، هر بار که کنش draw زده شده، کارت 2 آمده است. پس از دید داده‌ها، draw به شکل زیر عمل می‌کند:

$$(n, C) \xrightarrow{\text{draw}} (n + 2, C)$$

البته اگر $n + 2 \geq 6$ ، بازی تمام می‌شود. با تعداد خیلی زیاد نمونه، مقدارهای Q به مقدارهای زیر همگرا می‌شوند:

$$Q((0, C), \text{stop}) = 0, \quad Q((0, C), \text{draw}) = 4$$

$$Q((2, C), \text{stop}) = 2, \quad Q((2, C), \text{draw}) = 4$$

$$Q((3, C), \text{stop}) = 3, \quad Q((3, C), \text{draw}) = 5$$

$$Q((4, C), \text{stop}) = 4, \quad Q((4, C), \text{draw}) = 0$$

$$Q((5, C), \text{stop}) = 5, \quad Q((5, C), \text{draw}) = 0$$

این مقادارها لزوماً برابر Q^* واقعی نیستند، چون نمونه‌ها نماینده‌ی واقعی محیط نیستند و کارت‌های 3 و 4 اصلاً دیده نشده‌اند.

ه) در حالت $(4, C)$ داریم:

$$Q((4, C), \text{stop}) = 4$$

$$Q((4, C), \text{draw}) = 3$$

پس کنش حریصانه stop است. با $\epsilon = 0.4$ و دو کنش ممکن داریم:

$$P(\text{stop}) = (1 - \epsilon) + \frac{\epsilon}{2} = 0.6 + 0.2 = 0.8$$

$$P(\text{draw}) = \frac{\epsilon}{2} = 0.2$$

مقدار مورد انتظار Q بر اساس مقادارهای یادگرفته‌شده‌ی فعلی برابر است با:

$$\mathbb{E}[Q] = 0.8(4) + 0.2(3) = 3.8$$

اگر مقدار واقعی Q^* را معیار بگیریم، چون در حالت $(4, C)$ با draw حتماً می‌بازیم، داریم:

$$\mathbb{E}[Q^*] = 0.8(4) + 0.2(0) = 3.2$$

و) تعریف regret هر گام به صورت زیر است:

$$\text{regret}_t = V^*(s_t) - Q^*(s_t, a_t)$$

برای گام اول:

$$s_1 = (0, C), \quad a_1 = \text{draw}$$

$$\text{regret}_1 = V^*(0, C) - Q^*((0, C), \text{draw}) = \frac{10}{3} - \frac{10}{3} = 0$$

برای گام دوم:

$$s_2 = (2, C), \quad a_2 = \text{stop}$$

$$\text{regret}_2 = V^*(2, C) - Q^*((2, C), \text{stop}) = 3 - 2 = 1$$

برای گام سوم:

$$s_3 = (0, C), \quad a_3 = \text{draw}$$

$$\text{regret}_3 = V^*(0, C) - Q^*((0, C), \text{draw}) = 0$$

برای گام چهارم:

$$s_4 = (4, C), \quad a_4 = \text{draw}$$

$$\text{regret}_4 = V^*(4, C) - Q^*((4, C), \text{draw}) = 4 - 0 = 4$$

پس regret تجمعی برابر است با:

$$\text{Regret} = 0 + 1 + 0 + 4 = 5$$

$\text{Regret} = 5$

سؤال ششم

الف) برای به دست آوردن مدل گذار، تعداد رفتن‌ها از هر (s, a) به حالت بعدی را حساب می‌کنیم و بعد تقسیم بر کل دفعات همان (s, a) می‌کنیم:

$$\hat{T}(s, a, s') = \frac{N(s, a, s')}{N(s, a)}$$

برای حالت X ، کنش a سه بار آمده است؛ دو بار به Y و یک بار به Z :

$$\hat{T}(X, a, Y) = \frac{2}{3}, \quad \hat{T}(X, a, Z) = \frac{1}{3}$$

برای کنش b در حالت X ، هر دو بار به خود X رفته‌ایم:

$$\hat{T}(X, b, X) = 1$$

برای حالت Y ، کنش a سه بار آمده است؛ دو بار به Z و یک بار به Y :

$$\hat{T}(Y, a, Z) = \frac{2}{3}, \quad \hat{T}(Y, a, Y) = \frac{1}{3}$$

برای کنش b در حالت Y ، فقط یک بار آمده و به X رفته است:

$$\hat{T}(Y, b, X) = 1$$

برای حالت Z ، کنش a دو بار آمده و هر دو بار در خود Z مانده است:

$$\hat{T}(Z, a, Z) = 1$$

برای کنش b در حالت Z ، فقط یک بار آمده و به X رفته است:

$$\hat{T}(Z, b, X) = 1$$

بقیه‌ی حالت‌هایی که در داده نیامده‌اند، احتمالشان صفر در نظر گرفته می‌شود.

ب) برای پاداش، برای هر حالت و کنش، میانگین پاداش‌های همان قسمت را می‌گیریم:

$$\hat{R}(s, a, s') = \text{for reward average}(s, a, s')$$

اینجا پاداش فقط به s و a بستگی دارد و حالت بعدی مقدارش را عوض نکرده است. پس داریم:

$$\hat{R}(X, a, Y) = 3, \quad \hat{R}(X, a, Z) = 3$$

$$\hat{R}(X, b, X) = 1$$

$$\hat{R}(Y, a, Z) = 4, \quad \hat{R}(Y, a, Y) = 4$$

$$\hat{R}(Y, b, X) = 2$$

$$\hat{R}(Z, a, Z) = 0$$

$$\hat{R}(Z, b, X) = 5$$

برای بقیه‌ی گذارها هم چون احتمالشان صفر است، لازم نیست پاداشی حساب کنیم.

ج) فرمول یک مرحله از Value Iteration این است:

$$V_1(s) = \max_a \sum_{s'} \hat{T}(s, a, s') \left[\hat{R}(s, a, s') + \gamma V_0(s') \right]$$

چون در صورت سؤال گفته شده است که $V_0(s) = 0$ ، قسمت $\gamma V_0(s')$ صفر می‌شود. پس فقط میانگین پاداش هر کنش را حساب می‌کنیم:

$$V_1(s) = \max_a \sum_{s'} \hat{T}(s, a, s') \hat{R}(s, a, s')$$

برای حالت X :

$$Q_1(X, a) = \frac{2}{3}(3) + \frac{1}{3}(3) = 3$$

$$Q_1(X, b) = 1(1) = 1$$

پس:

$$V_1(X) = \max\{3, 1\} = 3$$

$$\pi(X) = a$$

برای حالت Y :

$$Q_1(Y, a) = \frac{2}{3}(4) + \frac{1}{3}(4) = 4$$

$$Q_1(Y, b) = 1(2) = 2$$

پس:

$$V_1(Y) = \max\{4, 2\} = 4$$

$$\pi(Y) = a$$

برای حالت Z :

$$Q_1(Z, a) = 1(0) = 0$$

$$Q_1(Z, b) = 1(5) = 5$$

پس:

$$V_1(Z) = \max\{0, 5\} = 5$$

$$\pi(Z) = b$$

در نتیجه داریم:

$$V_1(X) = 3, \quad \pi(X) = a$$

$$V_1(Y) = 4, \quad \pi(Y) = a$$

$$V_1(Z) = 5, \quad \pi(Z) = b$$

د) بله، Value Iteration در این MDP همگرا می‌شود. دلیلش این است که تعداد حالت‌ها و کنش‌ها محدود است و مقدار ضریب تخفیف هم کمتر از ۱ است:

$$\gamma = 0.9 < 1$$

یعنی اثر پاداش‌های خیلی دورتر، کم‌کم کمتر می‌شود و مقادارها به یک جواب ثابت می‌رسند. این‌که حالت Z با کنش a در خودش می‌ماند، مشکلی ایجاد نمی‌کند؛ چون باز هم ضریب تخفیف کمتر از ۱ است.